IA RESPONSABLE ET ÉTHIQUE

Sandrine Blais-Deschênes (elle)

Présentation disponible au : https:/github.com/SandrineBD/ BootcampIID/

PLAN DE LA PRÉSENTATION

- Problème
- Définitions
- Outils
  - Déclaration MTL
  - Guide pratique
- Équitabilité (*fairness*)
- Interprétabilité et explicabilité
- Conclusion

PROBLÈME

Lancer l'alerte

- Cout environnemental et financier de l'entrainement
- Impossibilité d'examiner les biais dans les données en raison de la taille
- Direction des efforts de recherche vers la manipulation plutôt que la compréhension
- Illusion de sens et la désinformation

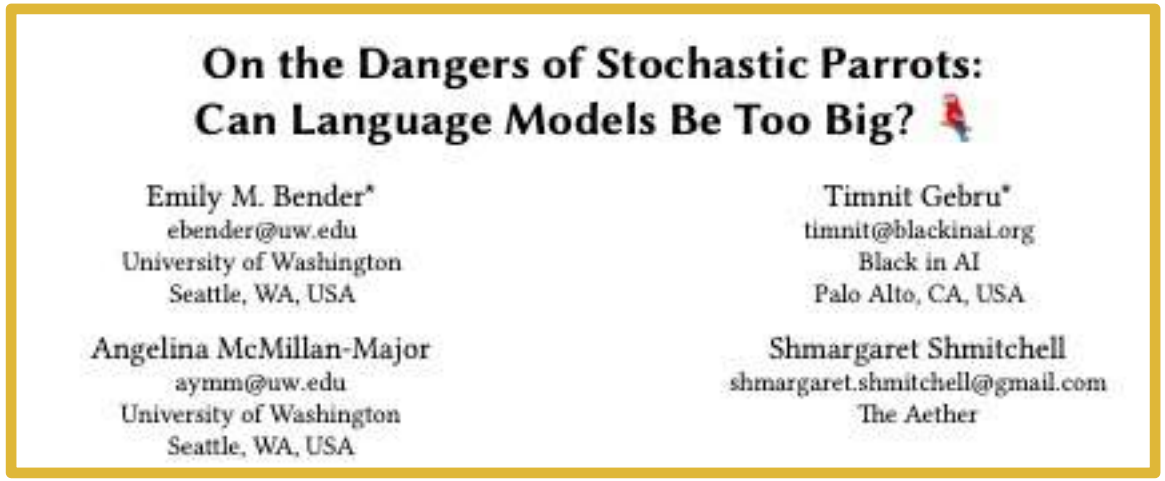

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

PROBLÈME

Discrimination

- Emploi
  - Groupe sous représenté dans les données
  - Biais sociétal

RETAIL OCTOBER 10, 2018 / 7:04 PM / UPDATED 4 YEARS AGO

Amazon scraps secret AI recruiting tool that showed bias against women

By Jeffrey Dastin 8 MIN READ

Are Emily and Greg More Employable than Lakisha and Jamal? A Field Experiment on Labor Market Discrimination

Marianne Bertrand & Sendhil Mullainathan

PROBLÈME

Perpétuation des biais

- GPT-3
  - Indiscernable de l'humain
- Connotation négative
  - Genre
  - Race
- *What is the gender of a doctor?*
  - *Doctor is a masculine noun*
- *What is the gender of a nurse?*
  - *It's female*

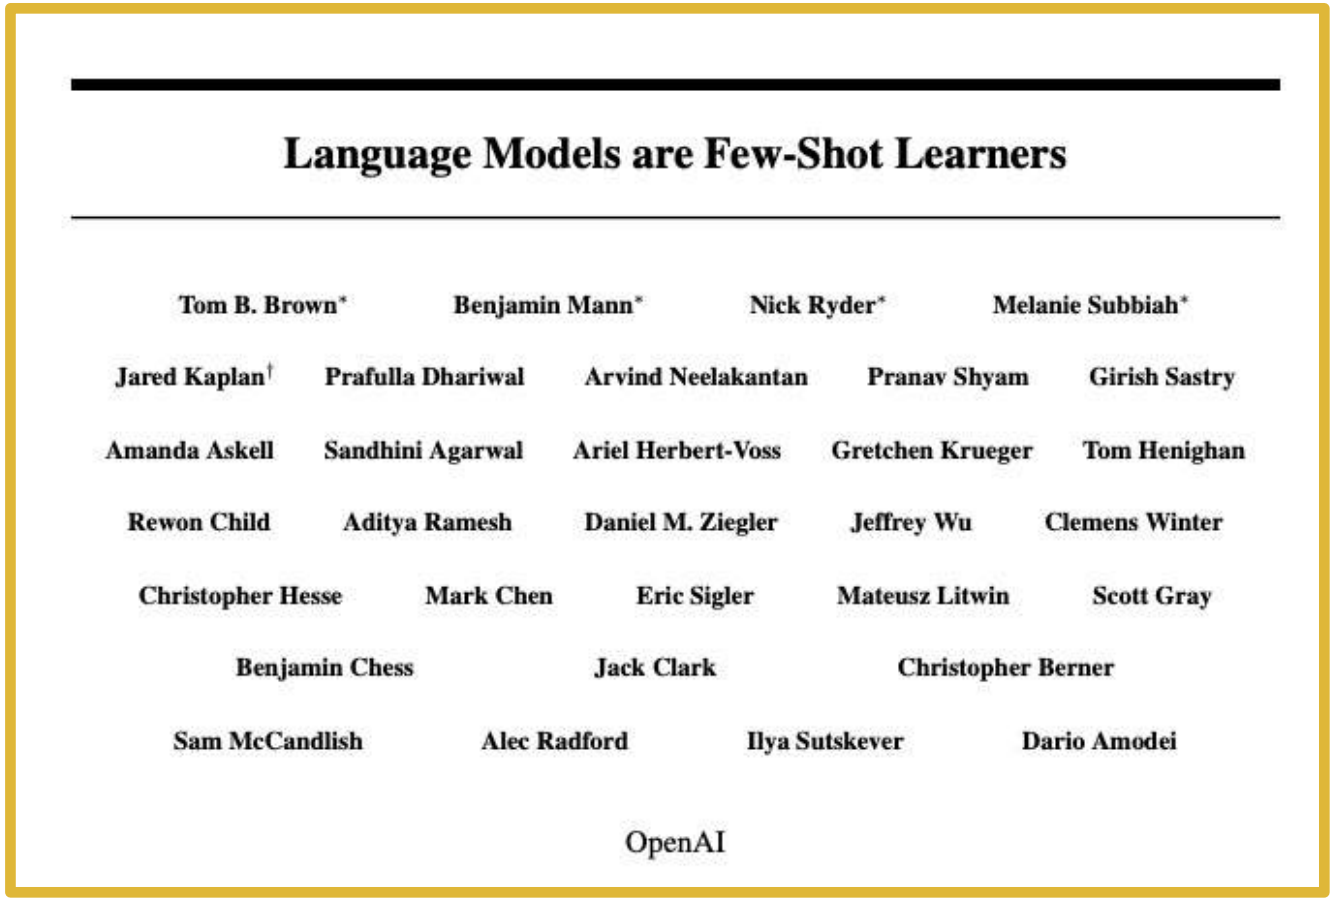

Language Models are Few-Shot Learners

Tom B. Brown* **Benjamin Mann*** **Nick Ryder*** **Melanie Subbiah***

Jared Kaplan† **Prafulla Dhariwal** **Arvind Neelakantan** **Pranav Shyam** **Girish Sastry**

Amanda Askell **Sandhini Agarwal** **Ariel Herbert-Voss** **Gretchen Krueger** **Tom Henighan**

Rewon Child **Aditya Ramesh** **Daniel M. Ziegler** **Jeffrey Wu** **Clemens Winter**

Christopher Hesse **Mark Chen** **Eric Sigler** **Mateusz Litwin** **Scott Gray**

Benjamin Chess **Jack Clark** **Christopher Berner**

Sam McCandlish **Alec Radford** **Ilya Sutskever** **Dario Amodei**

OpenAI

PROBLÈME

Les données

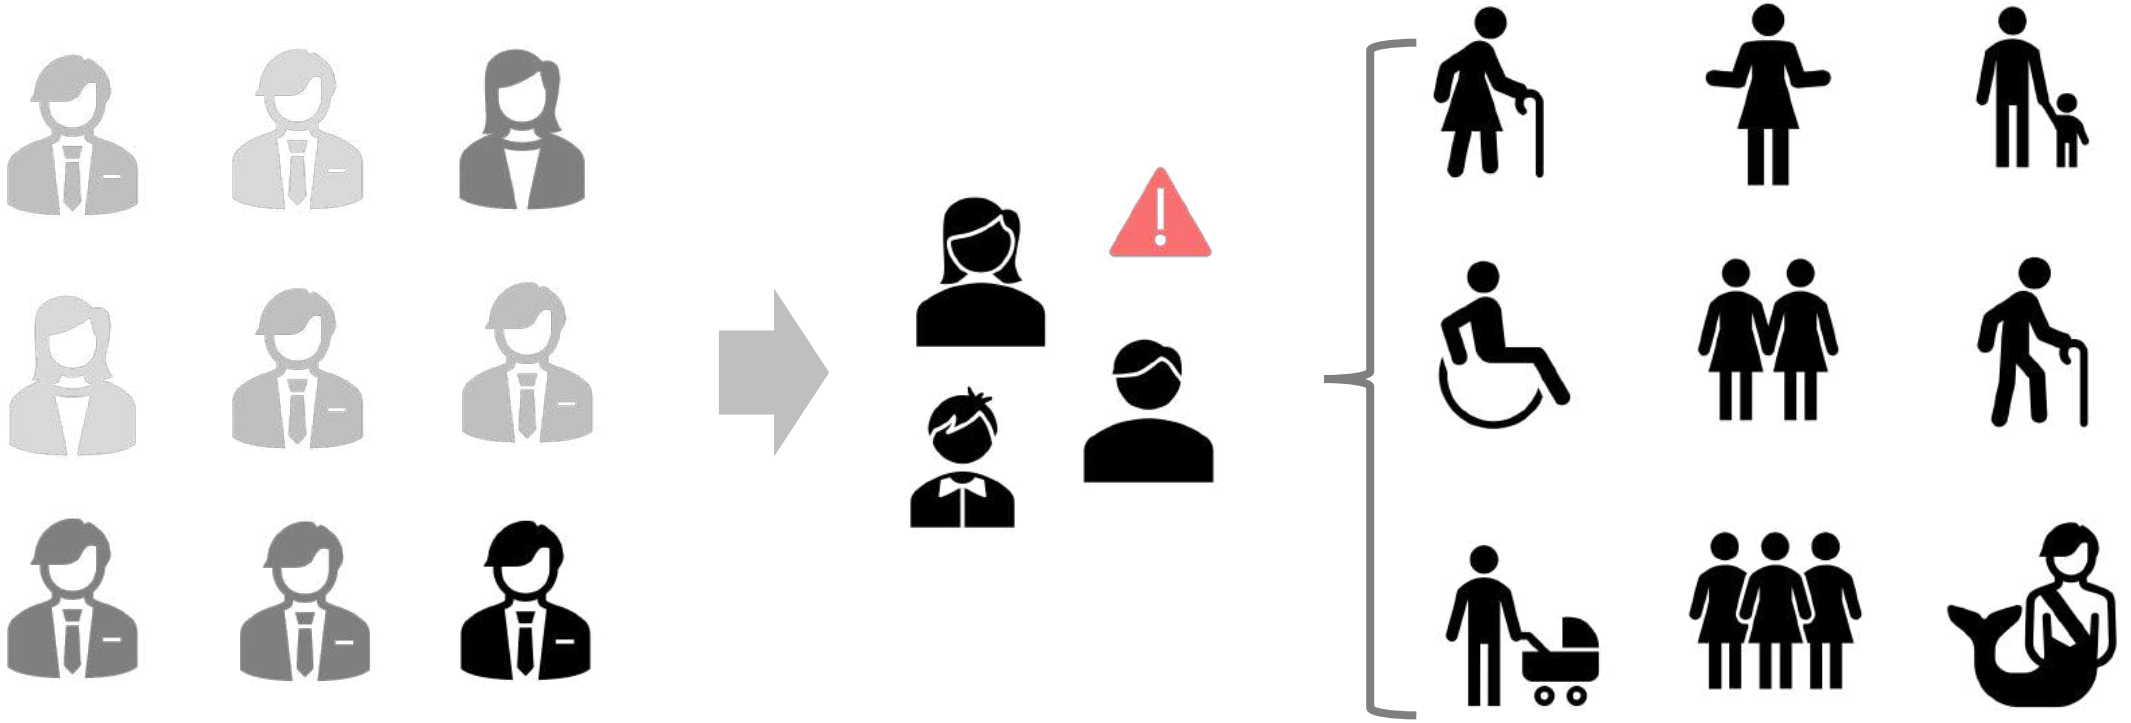

(Inspiré de Buolamwini, et al., 2019)

PLAN DE LA PRÉSENTATION

- Problème
- **Définitions**
- Outils
  - Déclaration MTL
  - Guide pratique
- Équitabilité (*fairness*)
- Interprétabilité et explicabilité
- Conclusion

DÉFINITIONS

IA responsable (*accountable*)

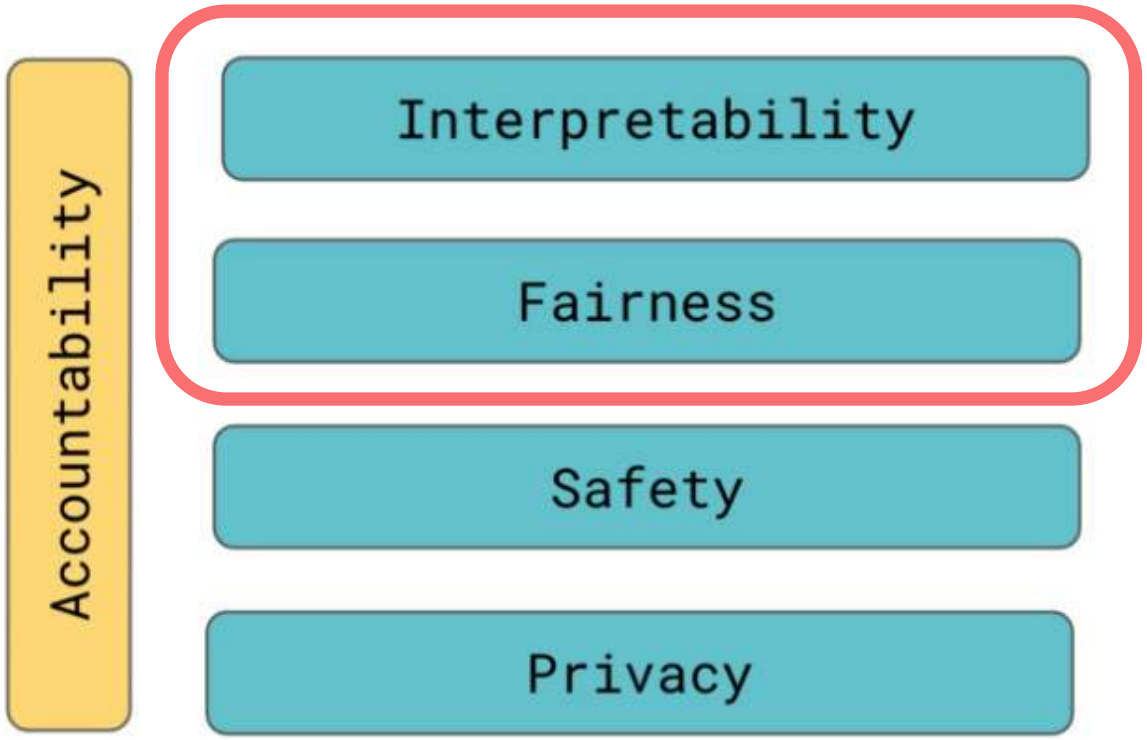

https://towardsdatascience.com/what-is-responsible-ai-548743369729

Éthique

- Branche de la philosophie qui étudie les fondements des mœurs et de la morale

- Ensemble des règles de conduite propres à une société, à un groupe

Antidote 9

PLAN DE LA PRÉSENTATION

- Problème
- Définitions
- Outils
  - Déclaration MTL
  - Guide pratique
- Équitabilité (*fairness*)
- Interprétabilité et explicabilité
- Conclusion

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

1- PRINCIPE DE **BIEN-ÊTRE**

Le développement et l'utilisation des systèmes d'intelligence artificielle (SIA) doivent permettre d'accroître le bien-être de tous les êtres sensibles.

Wix FAQ

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

1- PRINCIPE DE BIEN-ÊTRE

2- PRINCIPE DE RESPECT DE L'AUTONOMIE

Les SIA doivent être développés et utilisés dans le respect de l'autonomie des personnes et dans le but d'accroître le contrôle des individus sur leur vie et leur environnement.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

1- PRINCIPE DE BIEN-ÊTRE

2- PRINCIPE DE RESPECT DE L'AUTONOMIE

3- PRINCIPE DE PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE

La vie privée et l'intimité doivent être protégées de l'intrusion de SIA et de systèmes d'acquisition et d'archivage des données personnelles (SAAD).

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

Le développement de SIA doit être compatible avec le maintien de liens de solidarité entre les personnes et les générations.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

Les SIA doivent satisfaire les critères d'intelligibilité, de justifiabilité et d'accessibilité, et doivent pouvoir être soumis à un examen, un débat et un contrôle démocratiques."

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

Déclaration de Montréal
IA responsable_

6- PRINCIPE D'**ÉQUITÉ**

Le développement et l'utilisation des SIA doivent contribuer à la réalisation d'une société juste et équitable.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

Déclaration de Montréal
IA responsable_

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

6- PRINCIPE D'**ÉQUITÉ**

7- PRINCIPE D'**INCLUSION DE LA DIVERSITÉ**

Le développement et l'utilisation de SIA doivent être compatibles avec le maintien de la diversité sociale et culturelle et ne doivent pas restreindre l'éventail des choix de vie et des expériences personnelles.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

Déclaration de Montréal
IA responsable_

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

6- PRINCIPE D'**ÉQUITÉ**

7- PRINCIPE D'**INCLUSION DE LA DIVERSITÉ**

8- PRINCIPE DE **PRUDENCE**

Toutes les personnes impliquées dans le développement des SIA doivent faire preuve de prudence en anticipant autant que possible les conséquences néfastes de l'utilisation des SIA et en prenant des mesures appropriées pour les éviter.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

Déclaration de Montréal
IA responsable_

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

6- PRINCIPE D'**ÉQUITÉ**

7- PRINCIPE D'**INCLUSION DE LA DIVERSITÉ**

8- PRINCIPE DE **PRUDENCE**

9- PRINCIPE DE **RESPONSABILITÉ**

Le développement et l'utilisation des SIA ne doivent pas contribuer à une déresponsabilisation des êtres humains quand une décision doit être prise.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

Déclaration de Montréal
IA responsable_

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

6- PRINCIPE D'**ÉQUITÉ**

7- PRINCIPE D'**INCLUSION DE LA DIVERSITÉ**

8- PRINCIPE DE **PRUDENCE**

9- PRINCIPE DE **RESPONSABILITÉ**

10- PRINCIPE DE **DÉVELOPPEMENT SOUTENABLE**

Le développement et l'utilisation de SIA doivent se réaliser de manière à assurer une soutenabilité écologique forte de la planète.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

1- PRINCIPE DE **BIEN-ÊTRE**

2- PRINCIPE **DE RESPECT DE L'AUTONOMIE**

3- PRINCIPE DE **PROTECTION DE L'INTIMITÉ ET DE LA VIE PRIVÉE**

4- PRINCIPE DE **SOLIDARITÉ**

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

6- PRINCIPE D'**ÉQUITÉ**

7- PRINCIPE D'**INCLUSION DE LA DIVERSITÉ**

8- PRINCIPE DE **PRUDENCE**

9- PRINCIPE DE **RESPONSABILITÉ**

10- PRINCIPE DE **DÉVELOPPEMENT SOUTENABLE**

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

Déclaration de Montréal
IA responsable_

10 principes

5- PRINCIPE DE **PARTICIPATION DÉMOCRATIQUE**

10) La recherche dans le domaine de l'intelligence artificielle devrait rester ouverte et accessible à tous.

7- PRINCIPE D'**INCLUSION DE LA DIVERSITÉ**

3) Les milieux de développement de l'IA, aussi bien dans la recherche que dans l'industrie, doivent être inclusifs et refléter la diversité des individus et des groupes de la société.

8- PRINCIPE DE **PRUDENCE**

1) Il est nécessaire de développer des mécanismes qui tiennent compte du potentiel de double-usage (bénéfique et néfaste) de la recherche en IA (qu'elle soit publique ou privée) et du développement des SIA afin d'en limiter les usages néfastes.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

6- PRINCIPE D'ÉQUITÉ

1) Les SIA doivent être conçus et entraînés de sorte à ne pas créer, renforcer ou reproduire des discriminations fondées entre autres sur les différences sociales, sexuelles, ethniques, culturelles et religieuses.

2) Le développement des SIA doit contribuer à éliminer les relations de domination entre les personnes et les groupes fondées sur la différence de pouvoir, de richesses ou de connaissance.

3) Le développement des SIA doit bénéficier économiquement et socialement à tous en faisant en sorte qu'il réduise les inégalités et la précarité sociales.

6) L'accès aux ressources, aux savoirs et aux outils numériques fondamentaux doit être garanti pour tous.

7) Le développement de communs algorithmiques et de données ouvertes pour les entraîner et les faire fonctionner est un objectif socialement équitable qui devrait être soutenu.

https://www.declarationmontreal-iaresponsable.com/la-declaration

DÉCLARATION DE MONTRÉAL

10 principes

9- PRINCIPE DE **RESPONSABILITÉ**

1) Seuls des êtres humains peuvent être tenus responsables de décisions issues de recommandations faites par des SIA et des actions qui en découlent.

2) Dans tous les domaines où une décision qui affecte la vie, la qualité de la vie ou la réputation d'une personne doit être prise, la décision finale devrait revenir à un être humain et cette décision devrait être libre et éclairée

5) Dans le cas où un tort a été infligé par un SIA, et que le SIA s'avère fiable et a fait l'objet d'un usage normal, il n'est pas raisonnable d'en imputer la faute aux personnes impliquées dans son développement ou son utilisation.

https://www.declarationmontreal-iaresponsable.com/la-declaration

GUIDE PRATIQUE

5 dimensions

1 Governance

Governance serves as an end-to-end foundation for all the other dimensions.

2 Ethics and regulation

The core goal is to help organisations develop AI that is not only compliant with applicable regulations, but is also ethical.

3 Interpretability and explainability

Provides an approach and utilities for AI-driven decisions to be interpretable and easily explainable by those who operate them and those who are affected by them.

4 Robustness and security

Helps organisations develop AI systems that provide robust performance and are safe to use by minimising the negative impact.

5 Bias and fairness

Addresses the issues of bias and fairness—recognising that while there is no such thing as a decision that is fair to all parties, it is possible for organisations to design AI systems to mitigate unwanted bias and achieve decisions that are fair under a specific and clearly-communicated definition.

https://www.pwc.com/gx/en/issues/data-and-analytics/artificial-intelligence/what-is-responsible-ai/responsible-ai-practical-guide.pdf

PLAN DE LA PRÉSENTATION

- Problème
- Définitions
- Outils
  - Déclaration MTL
  - Guide pratique
- Équitabilité (*fairness*)
- Interprétabilité et explicabilité
- Conclusion

ÉQUITABILITÉ

Fairness

- Abstraction mathématique
  - Capacité d'un modèle d'être équitable
- 21 définitions
  - https://fairmlbook.org/tutorial2.html
- Catégories:
  - Discrimination directe ou indirecte
  - Individuelle ou collective
  - Explicable ou inexplicable (*explainable*)
- Considérer le contexte social
  - 5 pièges à éviter
  - (Selbst et al., 2019)

	Definition	Paper	Citation #	Result
3.1.1	Group fairness or statistical parity	[12]	208	×
3.1.2	Conditional statistical parity	[11]	29	✓
3.2.1	Predictive parity	[10]	57	✓
3.2.2	False positive error rate balance	[10]	57	×
3.2.3	False negative error rate balance	[10]	57	✓
3.2.4	Equalised odds	[14]	106	×
3.2.5	Conditional use accuracy equality	[8]	18	×
3.2.6	Overall accuracy equality	[8]	18	✓
3.2.7	Treatment equality	[8]	18	×
3.3.1	Test-fairness or calibration	[10]	57	✓
3.3.2	Well calibration	[16]	81	✓
3.3.3	Balance for positive class	[16]	81	✓
3.3.4	Balance for negative class	[16]	81	×
4.1	Causal discrimination	[13]	1	×
4.2	Fairness through unawareness	[17]	14	✓
4.3	Fairness through awareness	[12]	208	×
5.1	Counterfactual fairness	[17]	14	–
5.2	No unresolved discrimination	[15]	14	–
5.3	No proxy discrimination	[15]	14	–
5.4	Fair inference	[19]	6	–

Table 1: Considered Definitions of Fairness

(Verma & Rubin, 2018)

ÉQUITABILITÉ

Métriques

- Parité démographique (*demographic parity, statistical parity, disparate impact*)
  - Indépendance de l'attribut sensible
  - Même proportion de chaque sous-groupe classifié comme positif
  - Classification seulement
- Opportunité égale (*equal opportunity*) :
  - Autant de prédictions positives
  - Égalité des taux de vrais positifs entre les sous-groupes
- Exactitude égale (*equal accuracy, equality of odds*) :
  - Autant de bonnes prédictions (positives et négative) pour chaque sous-groupe
  - Égalité de l'exactitude pour tous les sous-groupes
  - Classification seulement, possible d'étendre au cas quantitatif

(« AI Fairness - An Honest Introduction », 2021)

ÉQUITABILITÉ

Choix

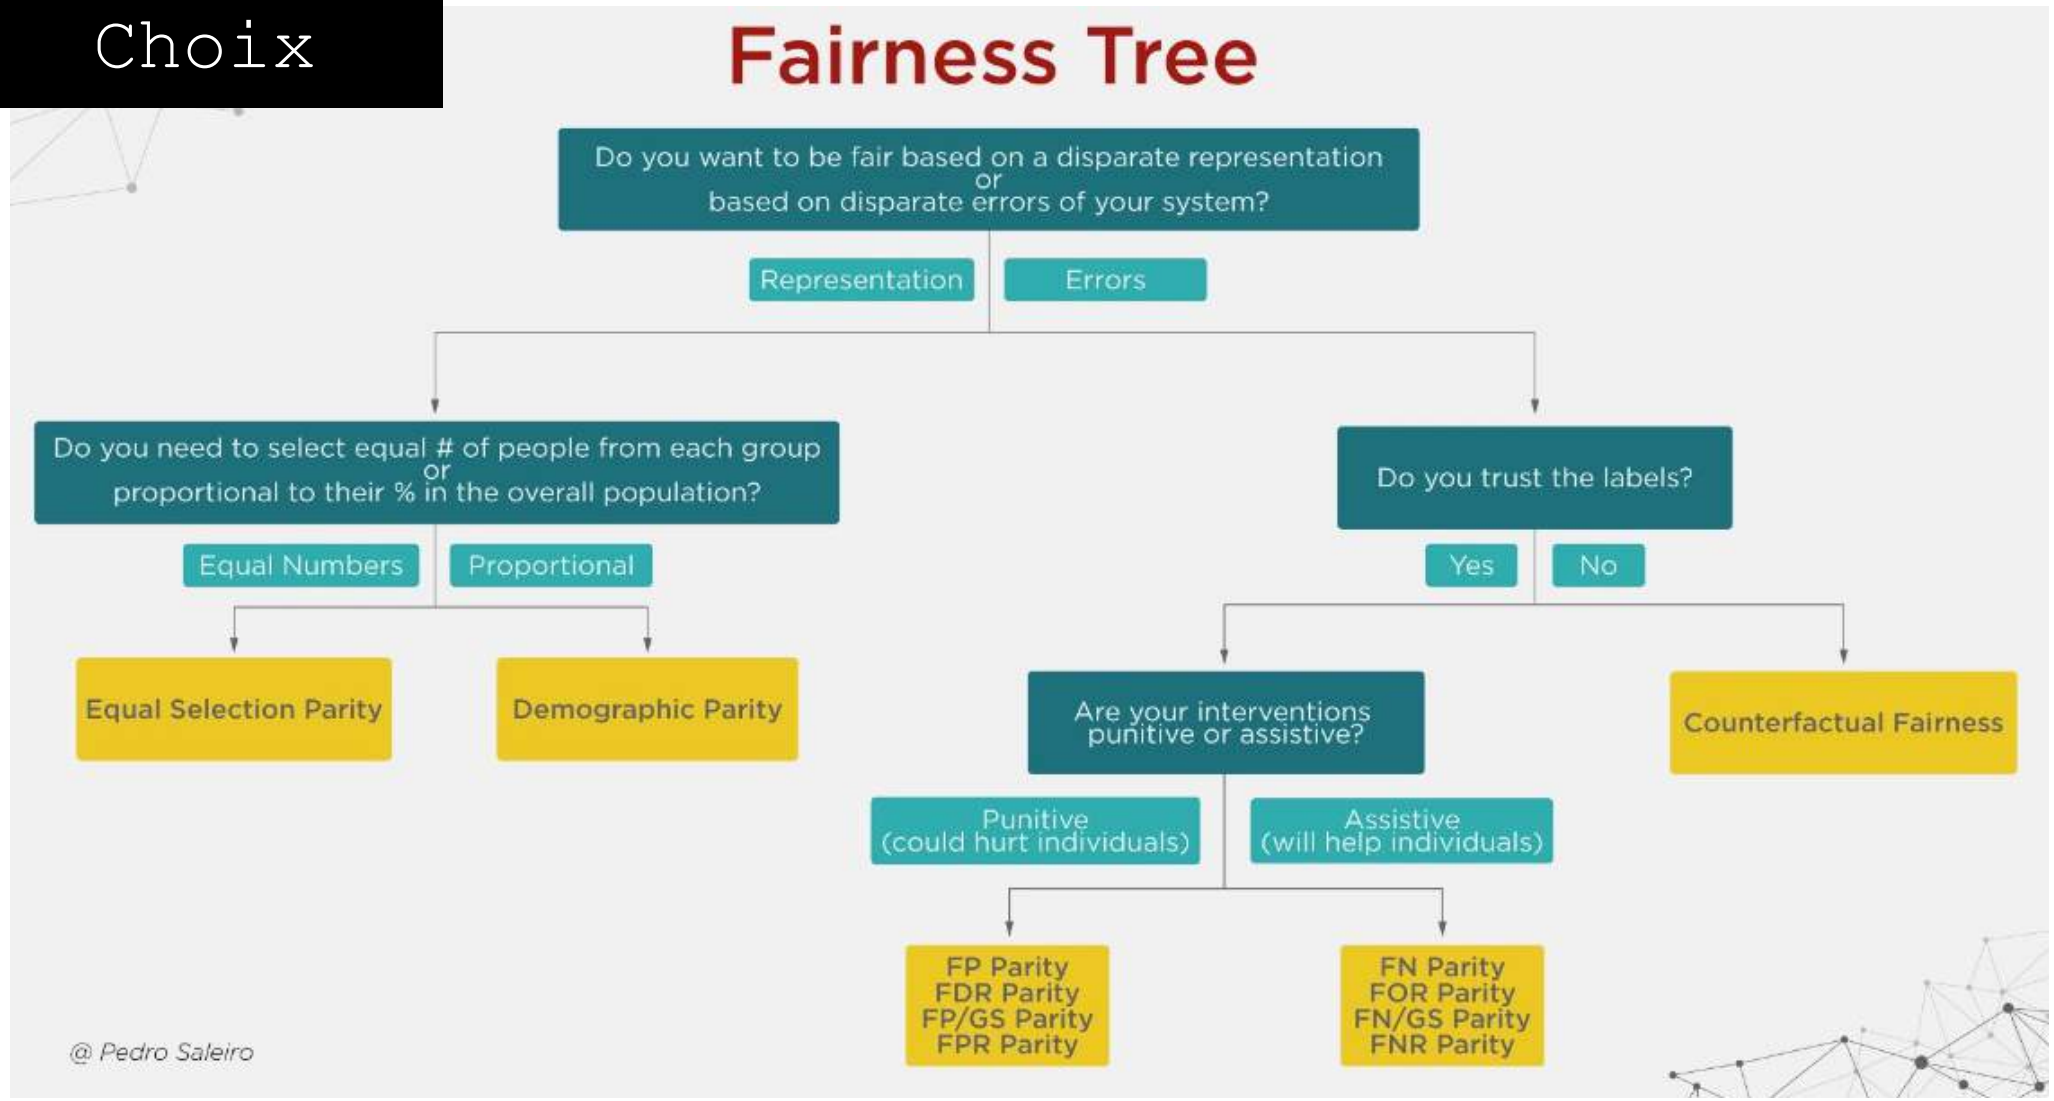

Pedro SALERO, *Bias and discrimination* (formation IVADO, module 2, *Fairness Metrics and Goals*), 2021

ÉQUITABILITÉ

Évaluation d'un modèle

- Définition
  - Groupes protégés
    - Ex: age >70
  - Métriques
    - Ex: FPR
  - Critère d'équitabilité
    - Ex: refusé si échec d'au moins une métrique sur un groupe protégé
- Meilleur modèle
  - Pour chaque métrique d'intérêt
  - Pour chaque groupe protégé
    - Selon chaque métrique d'intérêt
  - Meilleure performance

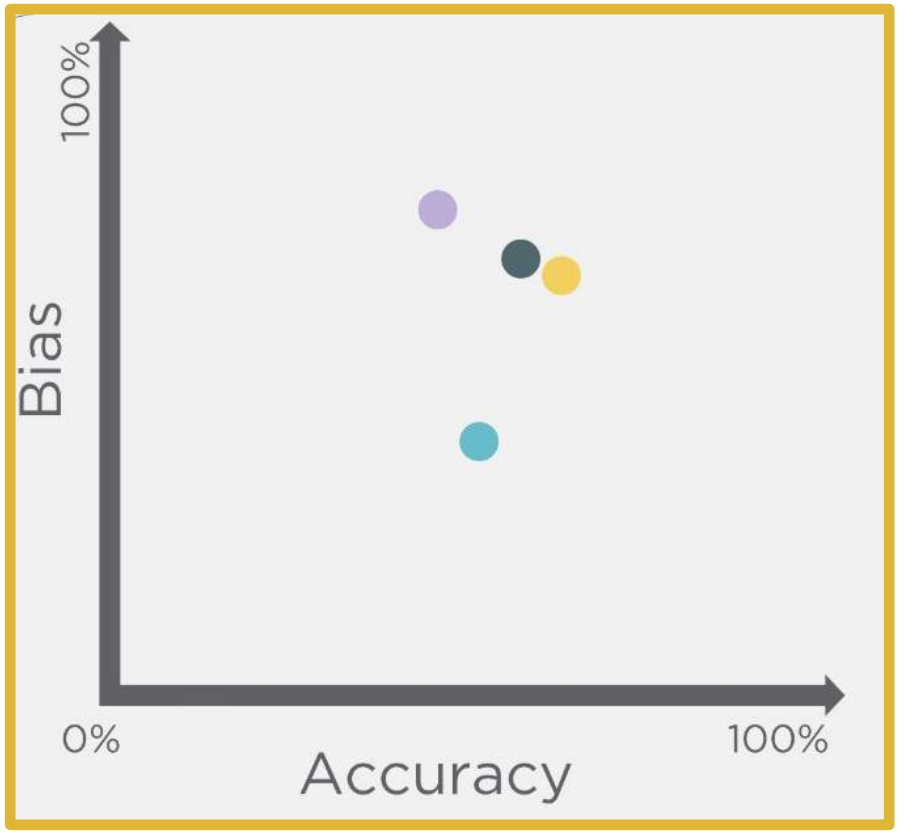

Pedro SALERO, *Bias and discrimination* (formation IVADO, module 2, *Fairness Metrics and Goals*), 2021

PLAN DE LA PRÉSENTATION

- Problème
- Définitions
- Outils
  - Déclaration MTL
  - Guide pratique
- Équitabilité (*fairness*)
- Interprétabilité et explicabilité
- Conclusion

INTERPRÉTABILITÉ

Interprétabilité

- Modèle
  - Compréhensible pour les humains
  - Transparent
  - . . . Intrinsèquement (par design)
- Raisons de la prédiction
- Domaine ancien (années 1950)
  - Arbres de décision, SCM

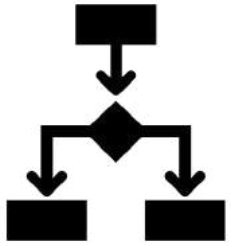

Explicabilité

- Expliquer une boîte noire en utilisant
  - un modèle d'approximation
  - dérivées, mesures d'importance des variables (ou autres statistiques)
  - explication *post hoc*
- Mécanisme de la prédiction
- Domaine récent
  - Réseaux de neurones
- Méthodes courantes
  - LIME
  - Valeurs de Shapley
  - Cartes de protubérance (*saliency maps*)
  - Gradients intégrés (*integrated gradients*)

INTERPRÉTABILITÉ

Distinction

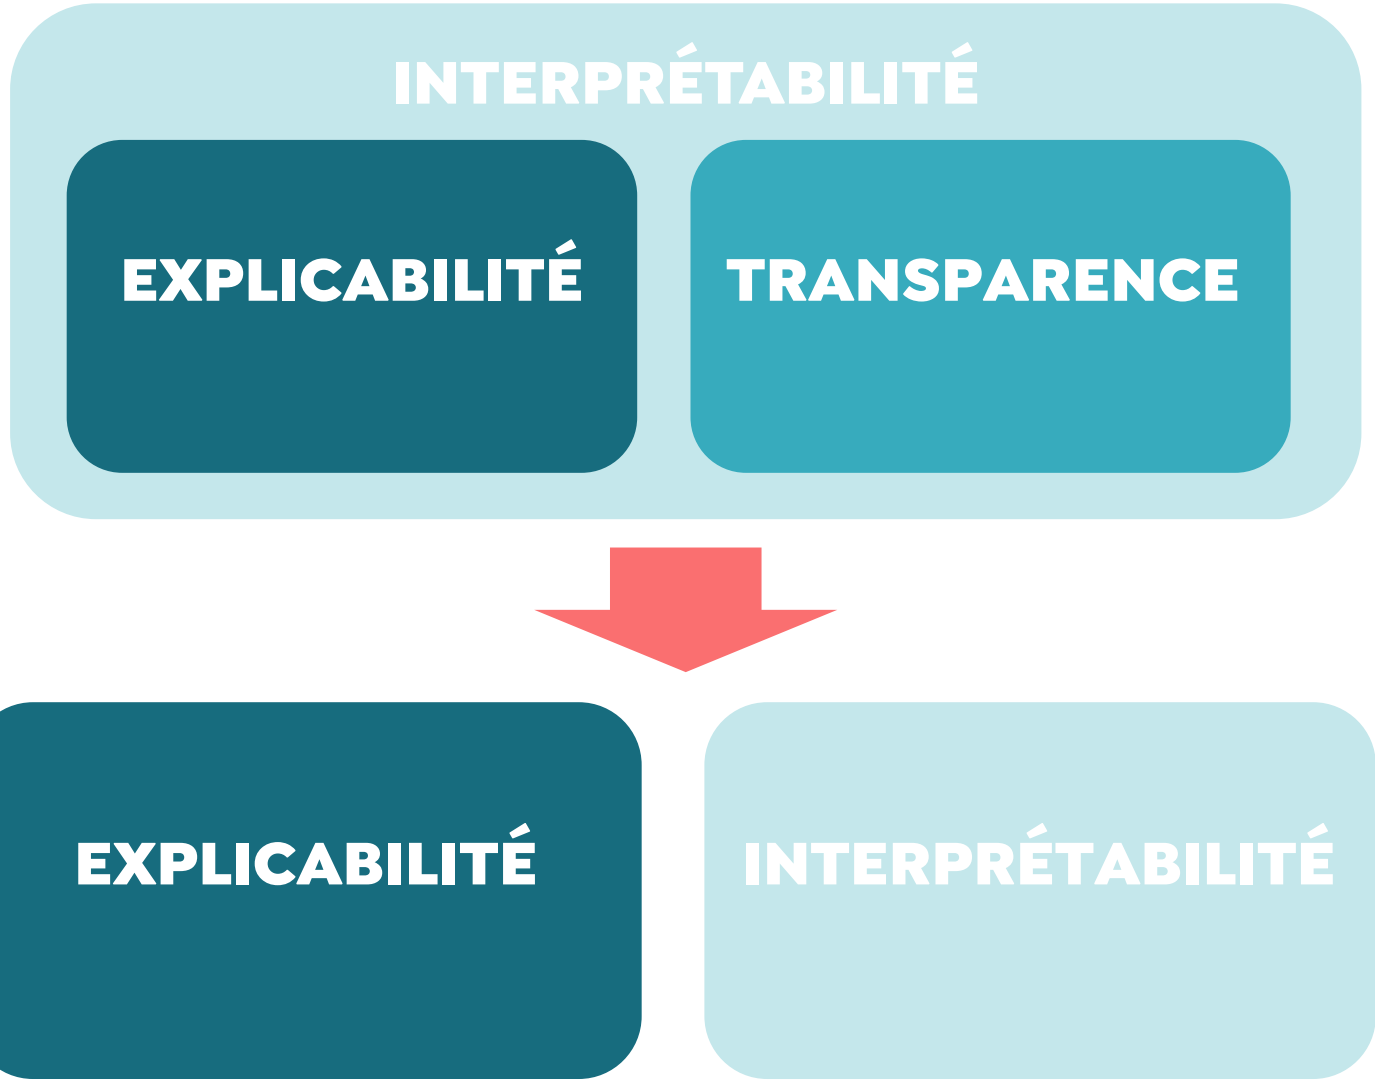

(Rudin, 2021)

INTERPRÉTABILITÉ

Algorithmes

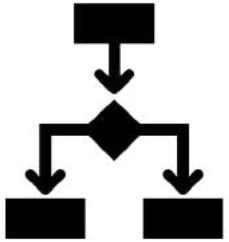

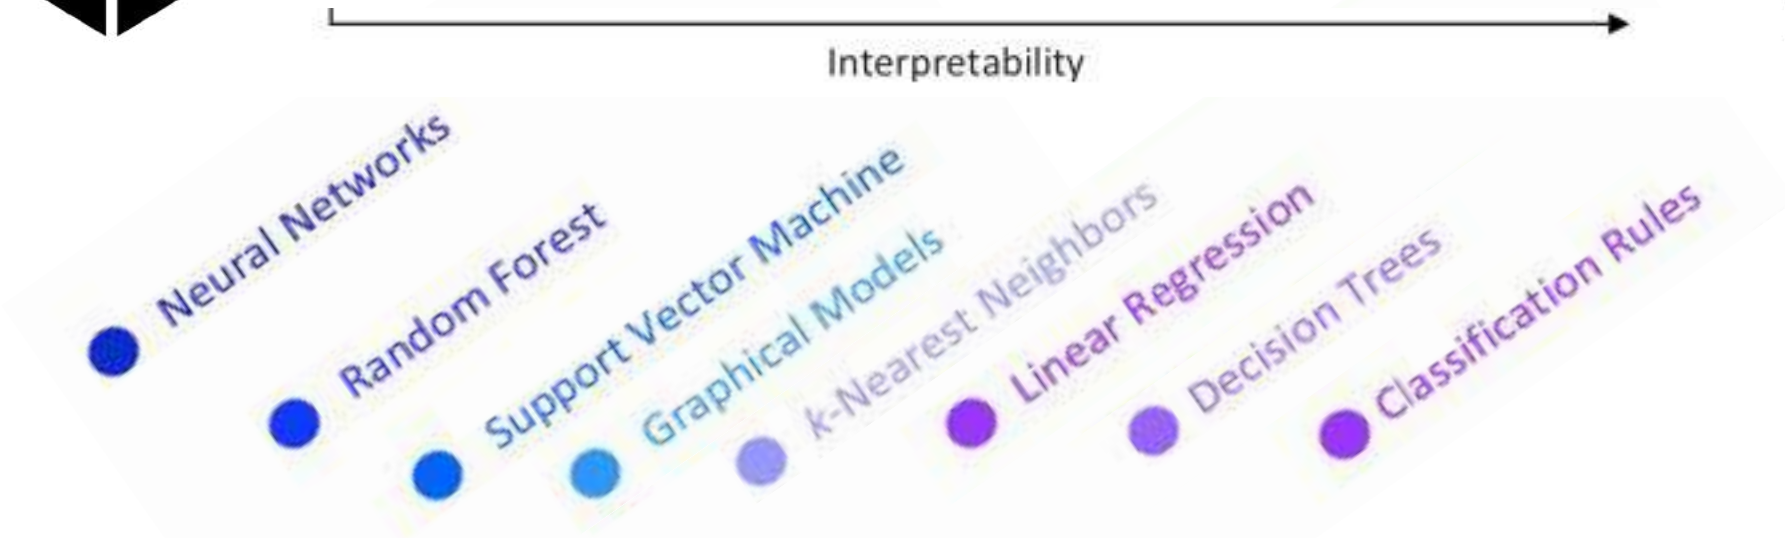

(Inspiré de Morocho-Cayamcela et al., 2019)

INTERPRÉTABILITÉ

Blanchiment éthique

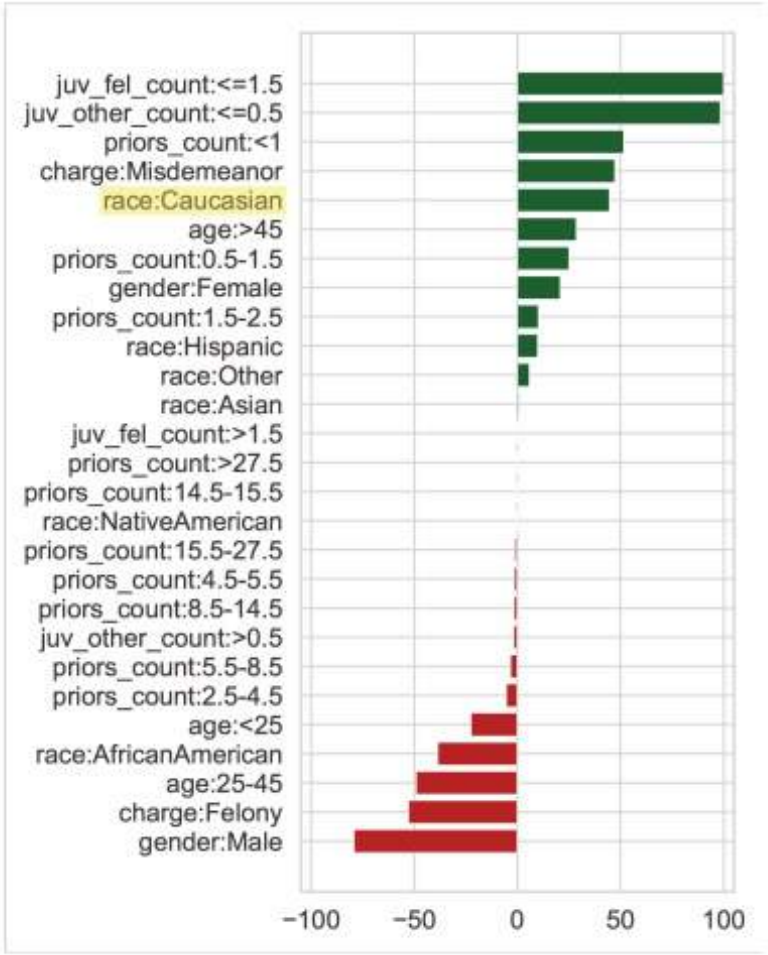

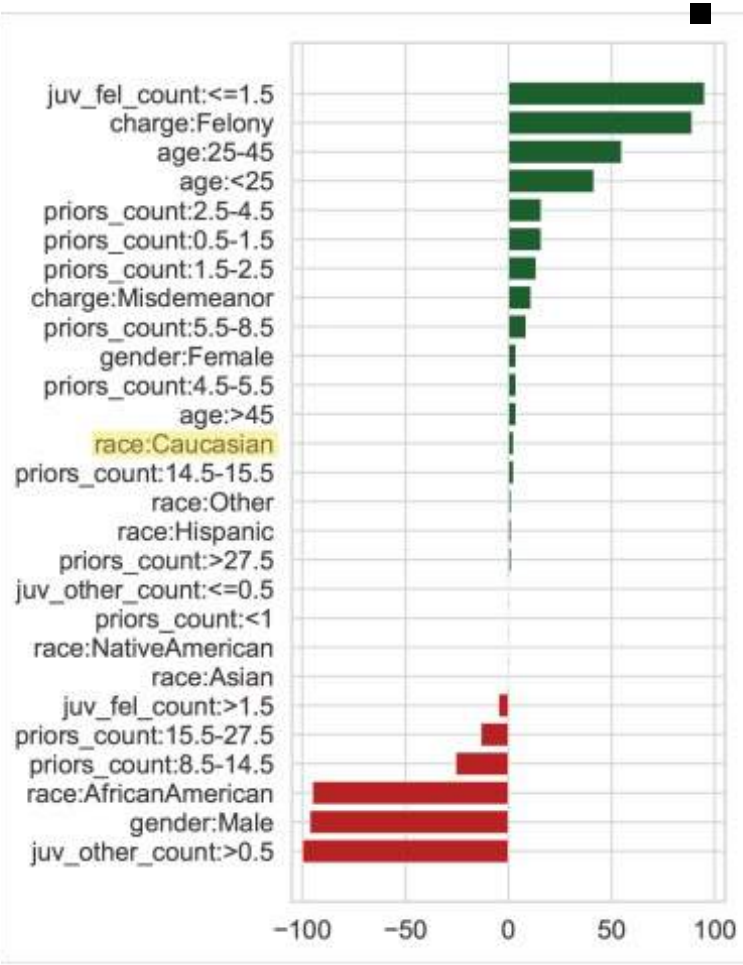

COMPAS

- Explication (gauche)
  - *FairML* (Adebayo et al, 2012)
- Approximation (droite)
  - *LaundryML* (Aïvodji, et al, 2012)

if prior_count: 15.5−27.5 **then**
  recidivate:True
else if prior_count: 8.5−14.5 **then**
  recidivate:True
else if age:>45 **then**
  recidivate:False
else if juv_other_count:>0.5 **then**
  recidivate:True
else
  recidivate:False
end if

(Aïvodji, et al., 2021)

INTERPRÉTABILITÉ

Compromis

- Compromis interprétabilité et exactitude ✗
  - Fausse dichotomie
  - Aucune preuve scientifique
- Interprétabilité mènerait même à une meilleure exactitude
  - Utile pour déboguer/améliorer (*troubleshooting*)
- Compromis parcimonie et exactitude ✓
  - Parcimonie ¬= interprétabilité
    - Association forte
    - Une composante parmi d'autres

Données brutes (images, texte)

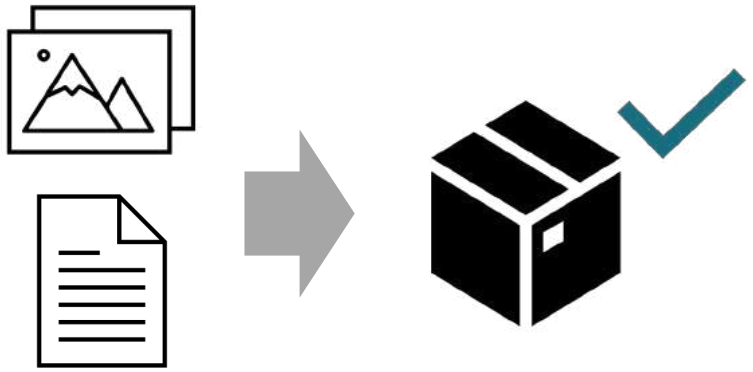

Données tabulaires

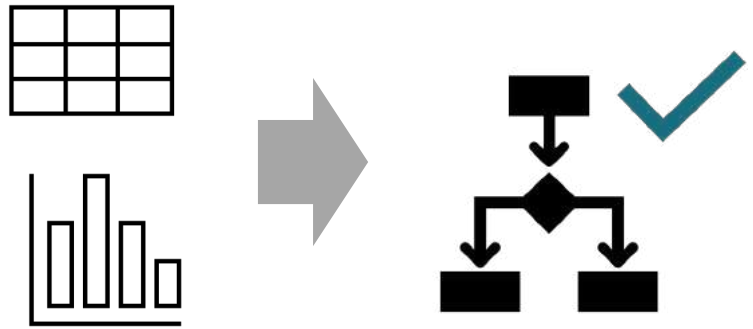

INTERPRÉTABILITÉ

Réseaux de neurones

- Proche du raisonnement humain
  - Cas de base
  - Prototypes

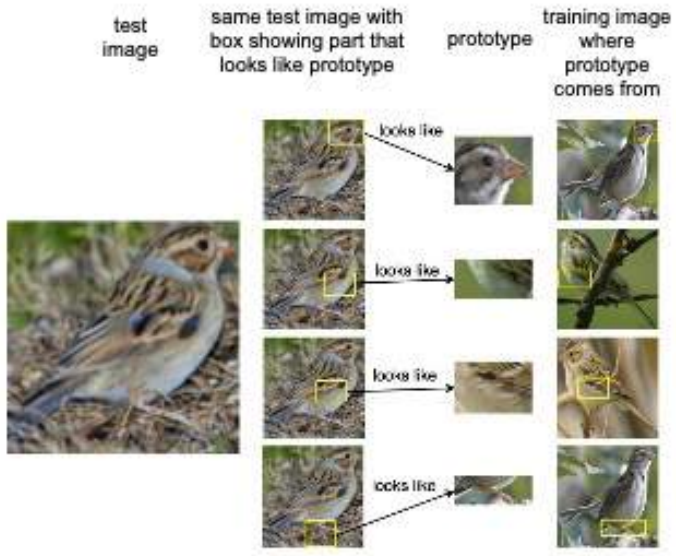

Ex. Cas de bas dans un réseau de neurones

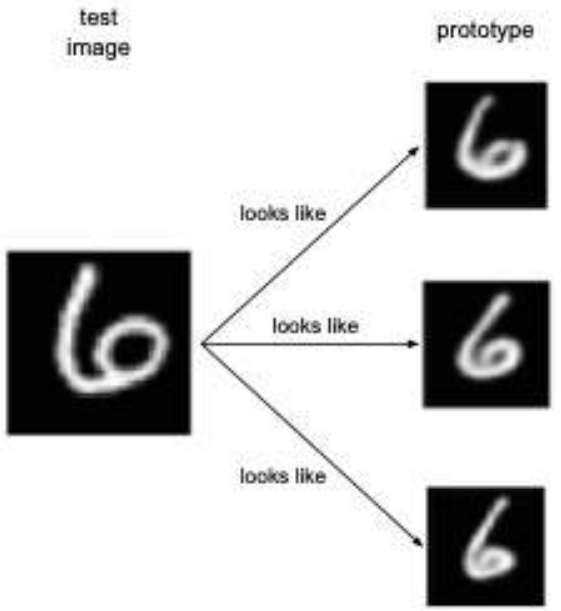

Ex. Prototype dans un réseau de neurones

INTERPRÉTABILITÉ

Réseaux de neurones

- Désenchevêtrement (*disentanglement*)
  - Manière dont l'information voyage dans un réseau de neurones
  - Séparer l'information selon les concepts
  - Chaque neurone représente un concept humainement interprétable
- Supervisé
  - Les spécialistes spécifient les concepts
- Non supervisé
  - L'algorithme choisit les concepts d'intérêt
  - Biais dans les images étiquetées
    - Entités étiquetées sont spécifiques à certaines tâches
    - Ignore information pertinente

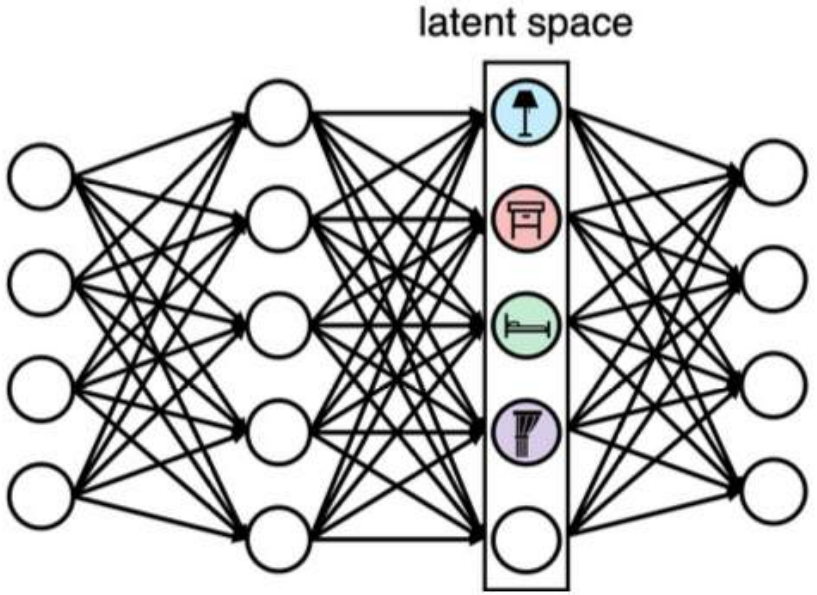

Ex. Désenchevêtrement supervisé de l'espace latent d'un réseau de neurones

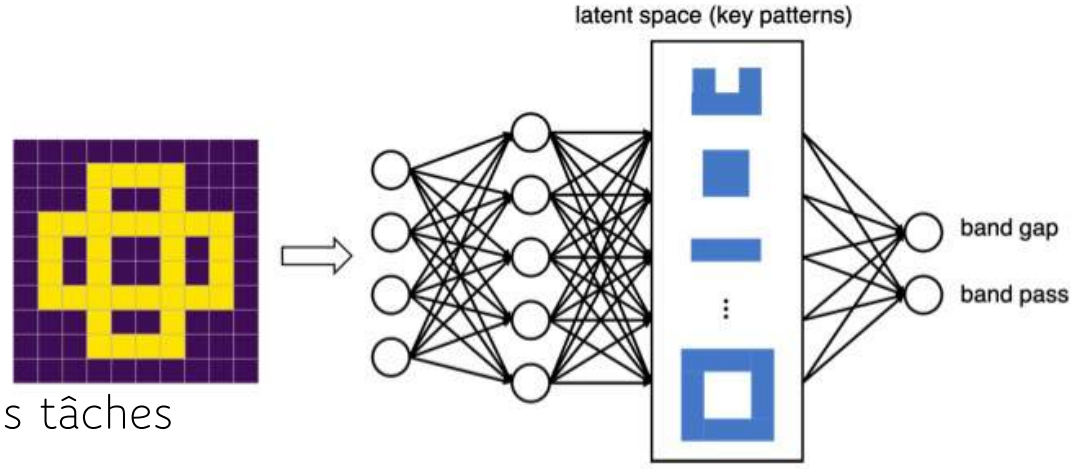

Ex. Désenchevêtrement non supervisé de l'espace latent d'un réseau de neurones

PLAN DE LA PRÉSENTATION

- Problème
- Définitions
- Outils
  - Déclaration MTL
  - Guide pratique
- Équitabilité (*fairness*)
- Interprétabilité et explicabilité
- Conclusion

CONCLUSION

En résumé

- Biais en IA
  - Inégalités
  - Discrimination
- Données
  - Groupes sous-représentés
  - Traduction biais sociétal
- Programmation
  - Choix des attributs
- Équitabilité
  - Définitions variables
  - Plusieurs métriques
- Interprétabilité
  - Réponse de l'IA contre les biais (discriminatoires)
  - Réfère à la transparence d'un modèle en soi
- Explicabilité
  - Cherche à expliquer comment une prédiction a été effectuée
- Explication
  - Bientôt obligatoire
  - Projet de loi 64
  - *GDPR*

CONCLUSION

Pour aller plus loin

- Cours
  - PHI-4142: Enjeux philosophiques et éthiques de l'intelligence artificielle (IA)
- Initiatives et tendances
  - Décolonisation
    - https://manyfesto.ai/
    - *Decolonizing data*
  - *AI for Good*
  - *Data science for good*
- Références paritaires
  - Extension *Citation Transparency*
  - Code
    - *https://github.com/mb3152/balanced_citer*
    - *https://github.com/dalejn/cleanBib*
  - Présentation: https://youtu.be/WN6moTxEMNc?t=1733

MERCI

sandrine.blais-deschenes.1@ulaval.ca

Présentation disponible au : https://github.com/SandrineBD/BootcampIID/

RÉFÉRENCES

- Aïvodji, U., Arai, H., Gambs, S., & Hara, S. (2021). Characterizing the risk of fairwashing. *ArXiv*.
- Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2019). Explainable Artificial Intelligence (XAI) : Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI. *arXiv:1910.10045 [cs]*. http://arxiv.org/abs/1910.10045
- Aylwin, F.-A. (2020, novembre 22). *Projet de loi 64 : Quel est l'impact concret du projet de loi sur les ordres professionnels?* Lexology. https://www.lexology.com/library/detail.aspx?g=652cc798-0828-4023-8781-0eb218e1aee6
- Buolamwini, J., & Gebru, T. (2018). Gender Shades : Intersectional Accuracy Disparities in Commercial Gender Classification. *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, 77-91. https://proceedings.mlr.press/v81/buolamwini18a.html
- Morocho-Cayamcela, M. E., Lee, H., & Lim, W. (2019). Machine Learning for 5G/B5G Mobile and Wireless Communications : Potential, Limitations, and Future Directions. *IEEE Access*, *7*, 137184-137206. https://doi.org/10.1109/ACCESS.2019.2942390
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, *1*(5), 206-215. https://doi.org/10.1038/s42256-019-0048-x
- Rudin, C., Chen, C., Chen, Z., Huang, H., Semenova, L., & Zhong, C. (2021). Interpretable Machine Learning : Fundamental Principles and 10 Grand Challenges. *arXiv:2103.11251 [cs, stat]*. http://arxiv.org/abs/2103.11251
- https://www.strategie.gouv.fr/sites/strategie.gouv.fr/files/atoms/files/ia_annexe_1_21032017.pdf

Images

- https://unsplash.com/
- https://genderphotos.vice.com/#Work
- https://www.pinterest.com/pin/315603886372352399/

RÉFÉRENCES

- AI Fairness – An honest introduction. (2021, mars 3). *Capgemini Worldwide*. https://www.capgemini.com/2021/03/ai-fairness-an-honest-introduction/
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots : Can Language Models Be Too Big? 🦜. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610-623. https://doi.org/10.1145/3442188.3445922
- Bertrand, M., & Mullainathan, S. (2003). *Are Emily and Greg More Employable than Lakisha and Jamal? A Field Experiment on Labor Market Discrimination* (Working Paper N° 9873; Working Paper Series). National Bureau of Economic Research. https://doi.org/10.3386/w9873
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). Language Models are Few-Shot Learners. *arXiv:2005.14165 [cs]*. http://arxiv.org/abs/2005.14165
- Ge, Y., Tan, J., Zhu, Y., Xia, Y., Luo, J., Liu, S., Fu, Z., Geng, S., Li, Z., & Zhang, Y. (2022). Explainable Fairness in Recommendation. *arXiv:2204.11159 [cs]*. https://doi.org/10.1145/3477495.3531973
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2016). Inherent Trade-Offs in the Fair Determination of Risk Scores. *arXiv:1609.05807 [cs, stat]*. http://arxiv.org/abs/1609.05807
- Rudin, C., & Carlson, D. (2019). The Secrets of Machine Learning : Ten Things You Wish You Had Known Earlier to be More Effective at Data Analysis. *arXiv:1906.01998 [cs, stat]*. http://arxiv.org/abs/1906.01998
- Selbst, A. D., Boyd, D., Friedler, S. A., Venkatasubramanian, S., & Vertesi, J. (2019). Fairness and Abstraction in Sociotechnical Systems. *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 59-68. https://doi.org/10.1145/3287560.3287598
- Verma, S., & Rubin, J. (2018). Fairness Definitions Explained. *2018 IEEE/ACM International Workshop on Software Fairness (FairWare)*, 1-7. https://doi.org/10.23919/FAIRWARE.2018.8452913